



# Spark企业级大数据项目实战 第11课



【声明】本视频和幻灯片为炼数成金网络课程的教学资料,所有资料只能在课程内使用,不得在课程以外范围散播,违者将可能被追究法律和经济责任。

课程详情访问炼数成金培训网站

http://edu.dataguru.cn

## 本课内容



- Spark优化与正确使用广播变量
- **ElasticSearch与Hbase整合**
- **■** Spark读写关系型数据库(集群与DB网络不通,Driver调优)
- Azkaban调度

## 炼数成金逆向收费式网络课程



- Dataguru(炼数成金)是专业数据分析网站,提供教育,媒体,内容,社区,出版,数据分析业务等服务。我们的课程采用新兴的互联网教育形式,独创地发展了逆向收费式网络培训课程模式。既继承传统教育重学习氛围,重竞争压力的特点,同时又发挥互联网的威力打破时空限制,把天南地北志同道合的朋友组织在一起交流学习,使到原先孤立的学习个体组合成有组织的探索力量。并且把原先动辄成干上万的学习成本,直线下降至百元范围,造福大众。我们的目标是:低成本传播高价值知识,构架中国第一的网上知识流转阵地。
- 关于逆向收费式网络的详情,请看我们的培训网站 http://edu.dataguru.cn

## 1 Spark优化与广播变量



#### 广播变量使用的场景

1. 减轻内存和网络传输开销, 降低GC频率 对于某个变量,如果不是用广播变量, 如果一个Executor中有N个task, 那么这个Executor中就有N个此变量的副本。

如果使用广播变量,在Executor中,只有一个此变量的副本。

避免Shuffle
 在Map端join, 没有shuffle

#### 1 Spark优化与广播变量-案例



## 广播变量:

## 1 Spark优化与广播变量-案例



## 使用变量:

```
方式一:
     val res2 = orders.mapPartitions(iter =>{
        val goodMap = goodinfoBroad.value
        val arrayBuffer = ArrayBuffer[(String,String,String)]()
        iter.foreach{case (goodsId,address,orderId) =>{
          if(goodMap.contains(goodsId)){
           arrayBuffer.+= ((orderId, goodMap.getOrElse(goodsId,""),address))
                                        方式二:
        arrayBuffer.iterator
                                              val res1 = orders.mapPartitions(iter => {
       })
                                                 val goodMap = goodinfoBroad.value
                                                 for{
                                                  (goodld, address, orderid) <- iter
                                                  if(goodMap.contains(goodId))
                                                 } yield (goodId, goodMap.getOrElse(goodId,""),address)
```

## 1 Spark优化与广播变量-正确使用广播变量



1. 如果不使用如下语句进行广播, 直接使用goods\_info进行关联?

val goodinfoBroad = sc.broadcast(goods\_info)

2. 将mapPartition改成map?

```
val res = orders.map(iter =>{
    val goodMap = goodinfoBroad.value
    val arrayBuffer = ArrayBuffer[(String,String,String)]()
    if(goodMap.contains(iter._1)){
        arrayBuffer.+= ((iter._1, goodMap.getOrElse(iter._1,""),iter._2))
    }
    arrayBuffer
}
```

每个Task都会复 goods info的部分 浪费资源 频繁创建goodMap =goodinfoBroad.value

## 1 Spark优化与广播变量-Spark SQL广播表



- 1. 将DataFrame注册成表 df.registerTempTable("smalltable") sql("CACHE TABLE smalTable")
- 2. 设置spark.sql.autoBroadcastJoinThreshold

spark.sql.autoBroadcastJoinThreshold默认为10 \* 1024 \* 1024Bytes

只有小于这个值的表才会被广播

错误的方式: sc.broadcast(df)

#### 不能将RDD或者DataFrame直接广播出去

#### 2 ElasticSearch与Hbase整合



Hbase二级索引

Hbase 非rowkey字段查询只能全表扫描,不支持模糊查询

#### 建立索引:

将hbase 需要索引的字段和rowkey存入Elasticsearch, 对于文档关键字有检索需求可以使用分词。

#### 根据二级索引字段查询:

- 1. 根据查询的字段条件,从Elasticsearch查询数据,并返回查询结果的rowkey。
  - 2. 根据第一步返回的rowkey, 去hbase检索数据,并返回结果集。



#### □读MySQL

var jdbcDf=sqlContext.read.format("jdbc").options(Map("url">"jdbc:mysql://localhost:3306/myspark",

"driver" -> "com.mysql.jdbc.Driver",

"dbtable"->"mytopic",

"user"->"root","password"->"123456")).load()

#### □ 写MySQL

// 将DataFrame数据写入mysql
val prop=new Properties()
prop.setProperty("user","root")
prop.setProperty("password","123456")
val url = "jdbc:mysql://localhost:3306/myspark"
df.write.mode(SaveMode.Append).jdbc(url,"my\_kafka",prop)



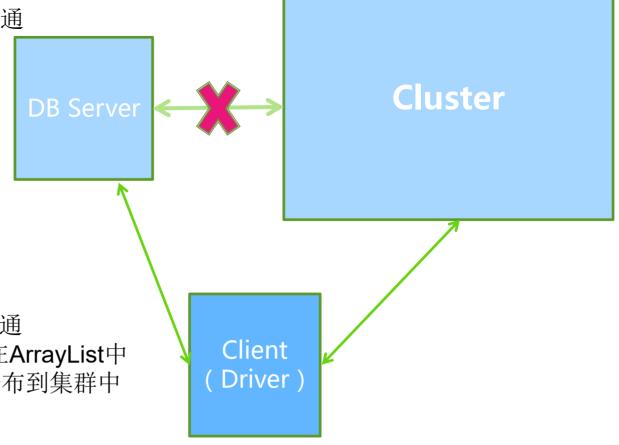


#### □ 写MySQL数据

- 1. Spark 程序提交使用yarn-client模式
- 2. Spark客户端与MySQL服务器和Hadoop集群网络连通
- 3. 从集群里面读取数据, rdd或者DataFrame,使用 collect算子, 将数据拉取到driver端
- 4. 在driver端(hadoop客户端)将数据写入到MySQL

#### □ 读MySQL

- 1. Spark 程序提交使用yarn-client模式
- 2. Spark客户端与MySQL服务器和Hadoop集群网络连通
- 3. 使用单机模式, 从MySQL读取数据, 将数据保存在ArrayList中
- 4. 使用MakeRDD或者parallalize 将数据转换成RDD分布到集群中





#### 分发本地集合形成RDD

```
def parallelize[T: ClassTag](
   seq: Seq[T],
   numSlices: Int = defaultParallelism): RDD[T] = withScope { }
// 与parallelize功能相同
def makeRDD[T: ClassTag](
   seq: Seq[T],
   numSlices: Int = defaultParallelism): RDD[T] = withScope { }
// 分配本地Scala集合以形成RDD,并为每个对象提供一个或多个位置首选项(Spark
节点的主机名)。为每个集合item创建一个新的分区。
def makeRDD[T: ClassTag](seq: Seq[(T, Seq[String])]): RDD[T] = withScope { }
```



#### Driver内存

#### collect 算子将数据拉取到driver端, driver内存必须足够大。

- \$ ./bin/spark-submit --class org.apache.spark.examples.SparkPi \
  - --master yarn \
  - --deploy-mode cluster \
  - --driver-memory 4g \
  - --executor-memory 2g \
  - --executor-cores 1 \
  - --queue thequeue \
    examples/jars/spark-examples\*.jar

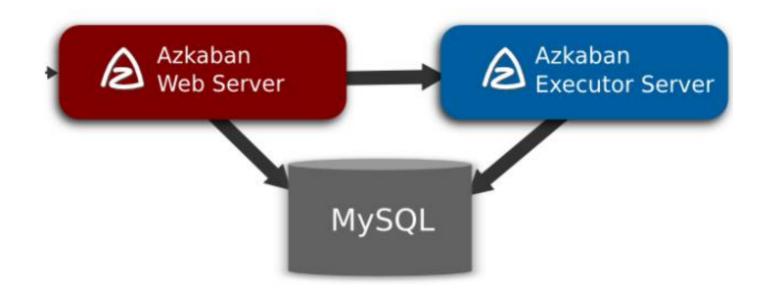


Spark读写ElasticSearch?



## 4 Azkaban调度

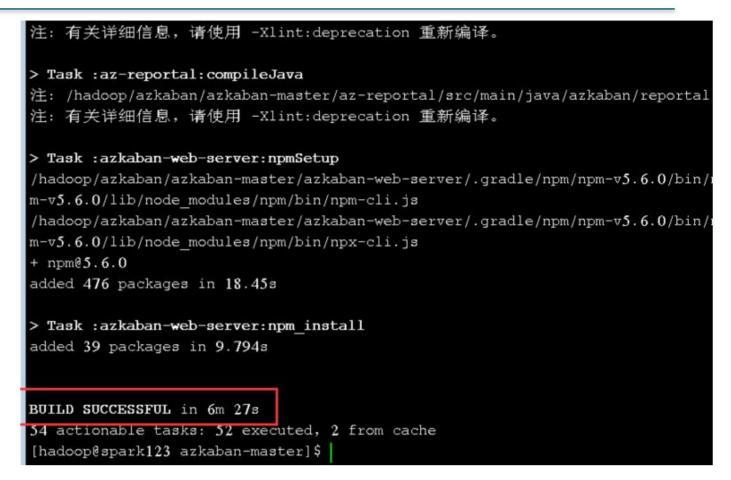




## 4 Azkaban 编译



- 1. 下载azkaban源码 github地址: https://github.com/azkaban/azkaban
- **2.** 在azkaban的源码目录编译 # Build without running tests ./gradlew build -x test



编译完成后截图

## 4 Azkaban三种模式



#### □ solo server mode

内置H2数据库, web server和executor server运行在同一个进程里。 仅用于测试场景。

#### □ two server mode

适用于比较严格的生产环境。 DB为应当为master-slave架构的MySQL数据库。 web server和executor server应当运行在不同的进程。

#### □ multiple executor mode

适用于最严格的生产环境。DB为应当为master-slave架构的MySQL数据库。web server和executor理想情况下应运行在不同的主机上, 以便升级和维护部影响用户。 这种多主机设置使Azkaban具备强大且可扩展的功能。

#### 4 Azkaban安装



- □ 数据库安装设置
- □ Azkaban Web Server安装配置
- □ Azkaban Executor配置

## 4 Azkaban使用



#### □ 服务启动

启动MySQL服务 启动WebServer 启动Executor

#### □ Azkaban 流程创建

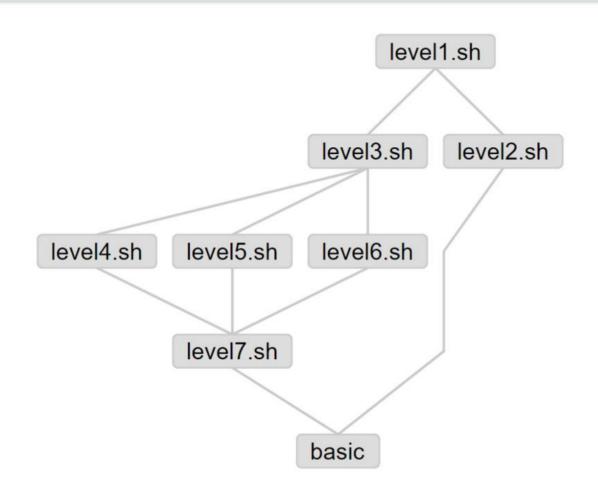
创建jobs 创建流程 嵌入式流程

#### □ Job配置

通用参数 运行时属性 继承的参数 参数变量替换

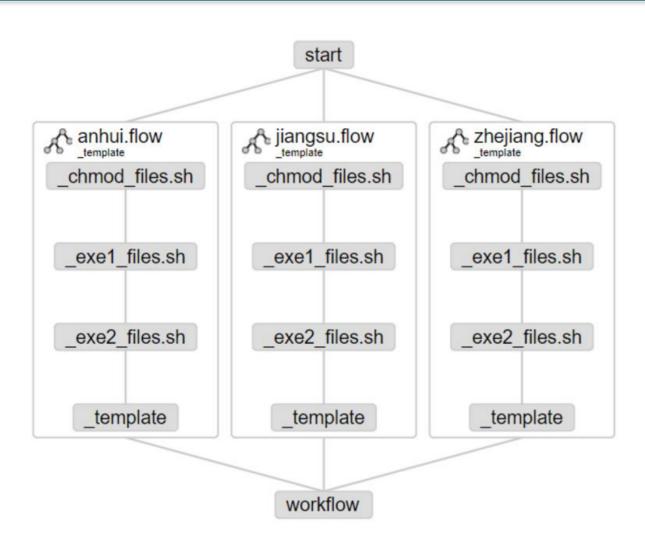
## 4 Azkaban使用案例1-基本流程





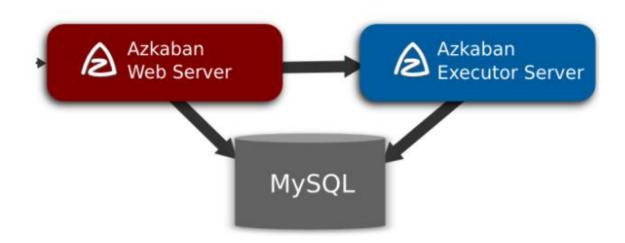
#### 4 Azkaban使用案例2-模板流程





## 4 Azkaban高可用





Azkaban Web Server: 两台主机, 使用Keepalive, 确保只有一台Web Server工作。

MySQL: 主从复制、HA

Azkaban Executor: Multiple Executor模式





# Thanks

# FAQ时间